



*Multi-Scale Semantic Tagging
for Lyrics-Based Music Structure Analysis
Using Lightweight Bidirectional Long Short-Term Memory*

Presenter: Shih-Yu Yo

Advisor: Prof. Sok-Ian Sou



Outline




- 1. Introduction
- 2. Related Works
- 3. Dataset and Pre-processing
- 4. System Architecture and Methodology
- 5. Experimental Results and Analysis
- 6. Conclusion






1.Introduction



1-1 Background





- **Music Structure Analysis** → Aims to segment music into semantically meaningful sections.
 - **Boundary Detection + Segment Labeling**



1-1 Background



- **Music Structure Analysis** → An indispensable task in **Music Information Retrieval**
 - Applications of **Music Information Retrieval**
 - Genre classification
 - Personalized recommendation
 - AI music production



1-2 Current Challenges and Contributions



- **1. Data Scarcity**

- Lack of dataset including “high-quality audio + timestamps + accurate lyrics + structural ground truth” simultaneously.
- → **Synchronized Dataset Construction**



1-2 Current Challenges and Contributions



- **2. Suboptimal Accuracy**
 - Recognition performance still has room for enhancement.
 - → **Competitive Cross-Modal Performance**



1-2 Current Challenges and Contributions



- **3. High Computational Cost**
 - SOTA Audio and Lyrics methods requires substantial GPU/CPU resources.
 - → **Resource-Efficient Architecture**





2.Related Works



2-1 Audio-Based Music Structure Analysis



- Signal processing techniques
 - Self-similarity matrix
- Supervised approaches
 - Convolutional Neural Networks
 - Recurrent Neural Networks
- → Difficult on constructing long-range dependency



2-1 Audio-Based Music Structure Analysis



- Transformer-based architectures

- SongFormer (2025)

- Require high-resolution spectrogram inputs and high computational cost

- → Motivates the exploration of alternative modalities with lower computational overhead.



2-2 Lyrics-based Music Structure Analysis



- Transformer-based architectures
 - LongFormer (2025)
 - Rely on general-purpose language representations
 - Do not explicitly incorporate music-specific structural characteristics
 - Ex. Semantic repetition and positional regularity
 - → The proposed framework captures structural regularities
 - Require high computational cost since they used “tokens” as input units
 - → The proposed framework utilize “line-level lyrics”



2-3 Multimodal Audio-Lyrics Modeling



- Utilizing model fusing Lyrics and Audio modality
 - MusicLIME (2024)
 - Require synchronized access to both audio and lyrics, increasing system complexity.
 - Existing works focuses on tasks such as genre or emotion recognition.





3.Dataset and Pre-processing



3-1 Data Integration and Synchronization





- Construct a synchronized corpus by **intersecting DALI v2.0 and the Harmonix Set**.

	DALI v2.0 Dataset	Harmonix Set	The Synchronized Dataset
Metadata	✓	✓	Synchronized Metadata
Timestamp	Line-level	Section-level	Line-level Timestamp
Lyrics	✓ (Line-level)	✗	Line-level Lyrics
Segment Labels	✗	✓ (Section-level)	Line-level segment labels
Audio File	Audio Files Link	Mel-Spectrogram	Audio Files and Mel-Spectrogram



3-2 Labeling and Class Distribution



ed9d55f03d5a4d35935f33b869048ddb_Never Too Late			
start_time	end_time	lyrics	harmonix_section
14.32	17.07	this world will never be,	Verse
17.48	20.17	what i expected.	Verse
20.79	23.43	and if i don't belong	Verse
23.89	26.07	who would have guessed it?	Verse
27.1	29.74	i will not leave alone	Pre-Chorus
30.31	33.05	everything that i own	Pre-Chorus
33.46	36.57	to make you feel like it's not too late.	Pre-Chorus
36.93	38.58	it's never too late	Pre-Chorus
39.93	42.77	even if i say	Chorus
42.72	45.93	it will be all right	Chorus
46.24	48.46	still i hear you say	Chorus
48.62	51.88	you want to end your life	Chorus
52.5	54.98	now and again we try	Chorus
55.13	57.62	to just stay alive	Chorus
58.24	60.26	maybe we'll turn it a round	Chorus
60.31	62.32	'cause it's not too late	Chorus
62.53	64.03	it's never too late	Chorus



3-2 Labeling and Class Distribution



Table 1: Class Distribution of The Synchronized Lyric Dataset

Category	Support (Lines)	Percentage (%)
Chorus	4681	48.45%
Verse	2899	30.00%
Bridge	1027	10.63%
Pre-Chorus	745	7.71%
Intro	206	2.13%
Outro	104	1.08%
Instruments	0	0.00%
Total	9662	100.00%






4.System Architecture and Methodology



4-1 System Architecture



4-1 System Architecture



- Given lyric lines $\mathcal{L} = \{L_1, L_2, \dots, L_N\}$

For line
 $i \in [1, n]$

Lyrics
 L_i


- The objective is to predict a sequence of structural labels

$$\mathcal{Y} = \{y_1, y_2, \dots, y_N\}, \quad y_i \in \mathcal{C}$$

- where $\mathcal{C}$ denotes the predefined set of structural categories



4-2 Feature Extraction



- **1.Semantic Features**

- Window context

$$W_i = \{L_{i-2}, L_{i-1}, L_i, L_{i+1}, L_{i+2}\}$$

- Section context


$$S_i = \{L_j \mid L_j \in \text{Paragraph}(L_i)\}$$

are encoded into 768-dimensional embeddings respectively as

$$E_{win} = f_{\text{RoBERTa}}(W_i), E_{sec} = f_{\text{RoBERTa}}(S_i)$$



4-2 Feature Extraction



- **2.Positional Features**


$$P_i = \frac{i}{N} \xrightarrow{\text{Normalize}} F_{pos}$$



4-2 Feature Extraction



A.Feature Extraction Layer




- **3.Repetitive Features**

- Self-similarity matrix

$$S_{i,j} = \begin{cases} \frac{\mathbf{e}_i \cdot \mathbf{e}_j}{\|\mathbf{e}_i\| \|\mathbf{e}_j\|}, & \text{if } i \neq j. \\ -1, & \text{if } i = j. \end{cases}$$



4-2 Feature Extraction



- 3. Repetitive Features**


$$R_i = [r_i^{(1)}, r_i^{(2)}, r_i^{(3)}]$$

$$\begin{cases} r_i^{(1)} = \max(\mathcal{S}_i) \\ r_i^{(2)} = \mathbb{I}(r_i^{(1)} > \tau_1) \\ r_i^{(3)} = \sum_{s \in \mathcal{S}_i} \mathbb{I}(s > \tau_2) \end{cases} \quad \begin{matrix} \tau_1 = 0.85 \\ \tau_2 = 0.80 \end{matrix}$$

$$R_i \xrightarrow{\text{Pooling}} F_{sim}$$



4-2 Feature Extraction



• 4.Feature Fusion


$$X_i = E_{win} \oplus E_{sec} \oplus F_{pos} \oplus F_{sim}$$



4-3 Temporal Modeling



B. Sequential Modeling Layer



- The concatenated feature vector sequence $\{X_1, \dots, X_N\}$
- is processed by a Bi-LSTM network to capture long-range dependencies

$$\vec{h}_i = \text{LSTM}_f(X_i), \quad \overleftarrow{h}_i = \text{LSTM}_b(X_i)$$

$$h_i = \vec{h}_i \oplus \overleftarrow{h}_i$$


- yielding a 512-dimensional hidden state.



4-4 Classification



C. Structure Prediction Layer




$$z_i = \text{ReLU}(\text{Linear}_{512 \rightarrow 256}(h_i))$$

$$\hat{y}_i = \text{Softmax}(\text{Linear}_{256 \rightarrow |C|}(z_i))$$





5.Experimental Results and Analysis



5-1 Experimental Setup



- 1) Evaluation Protocol → **5-fold cross-validation** (random_seed = 43)
- 2) Implementation Details
 - NVIDIA A100 GPU
 - Learning Rate: 1.88×10^{-4}
 - Weight Decay: 1.104×10^{-3}
 - Dropout Rate: 0.1
 - Optimizer: AdamW

$$\mathcal{L} = - \sum_{t=1}^N \sum_{c=1}^C y_{t,c} \log(\hat{y}_{t,c})$$



5-2 Feature Strategy



- **Mean Average Precision**
 - Measures the quality of semantic alignment between local windows and structural sections

A.Feature Extraction Layer




Table 2: RoBERTa Layer Selection Strategies and Performance

Strategy	Description	Dim.	MAP
Last Only	Output of Layer 12	768	0.4973
Second-to-Last	Output of Layer 11	768	0.4985
Last 4 Concat.	Concat. of Layer 9–12	3072	0.4993
Last 4 Average	Mean of Layer 9–12	768	0.4994



5-3 Model Comparison



- Evaluation Index
 - (1) Classification Performance
 - Precision

$$Precision = \frac{TP}{TP + FP}$$

- Recall

$$Recall = \frac{TP}{TP + FN}$$

- F1-Score

$$F1 = 2 \cdot \frac{Precision \cdot Recall}{Precision + Recall}$$



5-3 Model Comparison



- Evaluation Index
 - (2) Line-level Accuracy
 - Accuracy

$$\text{Accuracy} = \frac{\sum_{i=1}^N \mathbb{I}(\hat{y}_i = y_i)}{N}$$



5-3 Model Comparison



- Evaluation Index
 - (3) Structural Segmentation
 - **L-Measure** → Pairwise F1-score
 - Evaluates the global structural integrity by assessing whether pairs of time points throughout the song are correctly assigned to the same or different semantic categories.



5-3 Model Comparison




Table 4: Overall Performance Comparison of Different Models (Mean $\pm$ Std)


Model	Weighted F1	Accuracy	L-Measure
Proposed	0.7848 $\pm$ 0.0178	0.7867 $\pm$ 0.0175	0.7948 $\pm$ 0.0317
LongFormer	0.5672 $\pm$ 0.0408	0.6142 $\pm$ 0.0397	0.6398 $\pm$ 0.0432
SongFormer	0.5254 $\pm$ 0.0251	0.5448 $\pm$ 0.0193	0.6283 $\pm$ 0.0087



5-3 Model Comparison



5-3 Model Comparison



5-4 Ablation Analysis



Table 8: Ablation analysis on model components.

Configuration	Weighted F1	Drop (%)
Proposed Bi-LSTM	0.7848	-
w/o Repetition & Position	0.7805	0.55%
w/o Repetition, Position & Section	0.6783	13.57%
w/o Repetition, Position, Section & Window	0.4507	42.57%



5-5 Discussion and Limitations



- **1) Modality Limitation and Generalization**
 - Relies entirely on lyrics (text modality)
 - Limitations on **Instruments . Intro . Outro** sections
 - Dataset focus on modern English pop songs
 - → Future works
 - Integrate lightweight acoustic features
 - Experiments on songs of different genre or language



5-5 Discussion and Limitations




- **2) Dataset Scale**
 - Dataset contains only 148 songs / 9,662 lyric lines
 - Emphasis on quality over quantity (High-quality aligned annotations)
 - Performance evidence:
 - 5-fold cross-validation (song-level split)
 - Low performance variance





6.Conclusion



6 Conclusion




- Proposed a lightweight lyric-based music structure analysis model
 - Fusing “Semantic” and “Structure Prior” features with Bi-LSTM
 - 1. Synchronized Dataset Construction
 - 2. Competitive Cross-Modal Performance
 - 3. Resource-Efficient Architecture
- Leveraging lyrics for better music structure analysis and retrieval






Thanks for listening!




Global Information Modeling Selection

- Cascading Model (Transformer-Based)



Global Information Modeling Selection

- Hybrid Model (Transformer-Based)



Global Information Modeling Selection



Table 5.2: Global Information Modeling Method Selection (Weighted F1-score before fine-tuning)

Model Architecture	Weighted F1-score
Cascading Model	0.7042
Hybrid Model	0.7041
Proposed Bi-LSTM	0.7456



Global Information Modeling Selection



Table 5.4: Sectional Performance Metrics for Proposed Model (Mean $\pm$ Std)

Section	Precision	Recall	F1-Score
Intro	0.8152 $\pm$ 0.1062	0.4539 $\pm$ 0.0485	0.5798 $\pm$ 0.0497
Verse	0.8337 $\pm$ 0.0427	0.7424 $\pm$ 0.0563	0.7830 $\pm$ 0.0300
Pre-Chorus	0.5863 $\pm$ 0.0415	0.6671 $\pm$ 0.0570	0.6210 $\pm$ 0.0183
Chorus	0.8585 $\pm$ 0.0175	0.8995 $\pm$ 0.0200	0.8782 $\pm$ 0.0108
Bridge	0.5546 $\pm$ 0.1084	0.6194 $\pm$ 0.1606	0.5649 $\pm$ 0.0796
Outro	0.6583 $\pm$ 0.2585	0.4028 $\pm$ 0.2308	0.4429 $\pm$ 0.2492



Global Information Modeling Selection



Table 5.5: Sectional Performance Metrics for LongFormer Model (Mean $\pm$ Std)

Section	Precision	Recall	F1-Score
Intro	0.4500 $\pm$ 0.3930	0.0606 $\pm$ 0.0562	0.1038 $\pm$ 0.0923
Verse	0.6180 $\pm$ 0.0644	0.6029 $\pm$ 0.0992	0.6079 $\pm$ 0.0737
Pre-Chorus	0.1241 $\pm$ 0.1535	0.0383 $\pm$ 0.0479	0.0578 $\pm$ 0.0713
Chorus	0.6338 $\pm$ 0.0470	0.8455 $\pm$ 0.0497	0.7232 $\pm$ 0.0386
Bridge	0.4852 $\pm$ 0.1778	0.1850 $\pm$ 0.0815	0.2477 $\pm$ 0.0920
Outro	0.0000 $\pm$ 0.0000	0.0000 $\pm$ 0.0000	0.0000 $\pm$ 0.0000



Global Information Modeling Selection



Table 5.6: Sectional Performance Metrics for SongFormer Model (Mean $\pm$ Std)

Section	Precision	Recall	F1-Score
Intro	0.8253 $\pm$ 0.1658	0.9054 $\pm$ 0.0968	0.8452 $\pm$ 0.0868
Verse	0.4829 $\pm$ 0.0413	0.5792 $\pm$ 0.0784	0.5204 $\pm$ 0.0152
Pre-Chorus	0.3232 $\pm$ 0.1219	0.2240 $\pm$ 0.2123	0.2122 $\pm$ 0.1465
Chorus	0.6160 $\pm$ 0.0448	0.6018 $\pm$ 0.0431	0.6067 $\pm$ 0.0244
Bridge	0.1036 $\pm$ 0.0948	0.0947 $\pm$ 0.0906	0.0971 $\pm$ 0.0908
Outro	0.0000 $\pm$ 0.0000	0.0000 $\pm$ 0.0000	0.0000 $\pm$ 0.0000



Architecture of Baseline (SongFormer)




Fig. 1. Overall architecture of our proposed SongFormer for music structure analysis.

A. Feature Extraction Layer

Feature	提供給模型的資訊
Window Context	每行歌詞及其鄰近歌詞的局部語意資訊
Section Context	整個段落的整體語意與主題資訊
Repetitive Features	歌詞的重複模式，幫助辨識重複段落（如 Chorus）
$r_i^{(1)}$	與其他歌詞的最大語意相似度
$r_i^{(2)}$	是否存在極為高度相似的歌詞（0/1）
$r_i^{(3)}$	高度相似歌詞的數量
Positional Feature	歌詞在整首歌曲中的相對位置資訊

C. Structure Prediction Layer

元件	功能
Linear (512→256)	壓縮特徵維度，保留重要資訊。
ReLU	增加模型的非線性表達能力。
Dropout	降低過擬合，提高模型泛化能力。
Linear (256→7)	將特徵轉換為 7 個段落類別的分數（logits）。
Softmax	將分數轉換為各類別機率，選擇機率最高者作為預測結果。

Model Comparison

Section	Proposed Bi-LSTM	LongFormer	SongFormer
Intro	有一定表現，但因歌詞較少，缺乏明顯語意線索。	難以從少量歌詞建立結構概念，因此表現較差。	最佳，可利用開頭的能量、音色與配器變化辨識 Intro。
Verse	最佳，利用上下文語意與位置資訊，能掌握敘事內容。	能理解語意，但缺乏音樂結構先驗知識，容易混淆。	音訊變化較大且缺乏固定聲學特徵，因此辨識較困難。
Pre-Chorus	最佳，Position 與 Repetition Feature 能有效辨識過渡段。	過渡段樣本較少，且缺乏明確結構特徵，因此表現不佳。	Pre-Chorus 聲學特徵變化大，容易與 Verse 或 Chorus 混淆。
Chorus	最佳，歌詞高度重複，Repetition Feature 能充分發揮效果。	能利用 Transformer 找到部分重複，但不如顯式 Repetition Feature。	Chorus 的音訊變化較大，且不同歌曲編曲差異高，因此不如歌詞穩定。
Bridge	最佳，Section Context 能協助理解語意轉折，因此辨識較佳。	Bridge 樣本少且結構多變，容易被誤判。	Bridge 沒有固定音訊模式，泛化能力有限。
Outro	有一定表現，若歌詞具有結尾語意或重複，可成功辨識。	幾乎無法辨識，樣本極少且缺乏有效結構資訊。	多數 Outro 為純演奏或漸弱結尾，缺乏歌詞且音訊模式不固定，因此表現最差。

Evaluation Index Comparison

評估指標	比較重點	適合評估
Weighted F1-Score	考慮類別不平衡的分類表現	各段落分類能力
Accuracy	整體分類正確率	每行歌詞是否分類正確
L-Measure	預測結構與真實結構的一致性	整首歌曲的段落切分品質

L-Measure (Pairwise F1-score)



$$P = \frac{|P_{\text{pred}} \cap P_{\text{gt}}|}{|P_{\text{pred}}|}$$

$$R = \frac{|P_{\text{pred}} \cap P_{\text{gt}}|}{|P_{\text{gt}}|}$$

$$L\text{-Measure} = \frac{2PR}{P + R}$$

將逐行的預測結果透過時間戳映射回連續的時間軸上，接著在整首歌當中隨機抽取任意兩個時間點

如果 Ground Truth 認為這兩個時間點屬於同一個音樂段落，而模型也預測正確，這才算一個 True Positive

換句話說，如果模型出現段落破碎、預測標籤反覆跳變的狀況，這個分數就會大幅塌陷。



Q&A



Q：為什麼早期方法難以捕捉長距離的結構依賴？

A：

方法	為什麼難以捕捉長距離結構？
Self-Similarity Matrix (SSM)	只能描述兩兩片段的相似性，缺乏對整體歌曲結構與上下文的理解。
Convolutional Neural Networks (CNNs)	卷積主要關注局部區域，需要堆疊很多層才能擴大感受野，因此不易學習跨段落的長距離關係。
Recurrent Neural Networks (RNNs)	資訊必須逐步傳遞，長距離資訊容易衰減或遺失（梯度消失），因此較難建模整首歌的全域結構。



Q&A



Q：那為什麼 Transformer 比較好？

A：Transformer 利用 Self-Attention，可以直接建立任意兩個位置之間的關聯，因此比 CNN 和 RNN 更容易捕捉歌曲中跨段落的長距離結構，例如前後兩段 Chorus 或 Verse 之間的關係。



Q&A



Q：為什麼你的模型比 LongFormer 好？

A：不是因為 Bi-LSTM 比 Transformer 強，而是加入了 Position、Repetition、Section embedding 提供了 music-aware inductive bias

Q：為什麼可以贏 SongFormer？

A：SongFormer 依靠 acoustic feature

Lyrics 直接包含 semantic、repetition；因此：Verse、Chorus 反而更容易辨識

Q：如果資料增加10倍，你覺得還會贏 SongFormer 嗎？

A：不一定，SongFormer 在大量資料下，Audio 優勢可能更明顯

我的模型優勢主要在：資料有限、資源有限、Edge deployment



Q&A



Q：如何證明模型具有泛化能力而沒有過擬合？

**A：採用基於歌曲切分的 5-Fold Cross Validation，確保同一首歌不會同時出現在訓練集與測試集；
實驗結果 Weighted F1 的 σ 只有0.0178，證明模型捕捉的是通用的音樂結構規律，而非特定歌曲的特徵；
模型核心的 RoBERTa 編碼器是預訓練好的，本身就帶有龐大的外部語言知識，後級輕量的 Bi-LSTM 只需要學習結構映射邏輯，因此在小規模數據下也能快速收斂且不易過擬合。**



Q&A



Q：在 RoBERTa 層選擇實驗中，為什麼 Last 4 Average 會優於 Last Only？

A：雖然 Transformer 的最後一層擅長捕捉微觀的語法與詞彙特徵，但音樂結構分析更依賴段落之間高層次的語義連貫性；

Transformer 的中高層被證實含有更豐富的段落級上下文；

實驗表明，平均最後 4 層（MAP 達 0.4994）不僅能提供更高保真度的語義輸入，且平均後的 768 維度更為緊湊，能顯著減少後續 Bi-LSTM 的參數配置與計算複雜度，達成資源高效的設計目標。



Q&A



Q：論文強調這是面向 IoT 邊緣部署的輕量化架構，雖然 Bi-LSTM 很小，但前級使用的 RoBERTa-base 擁有 124M 參數（約 475MB 靜態記憶體），在資源受限的設備上跑得動嗎？

A：在訓練與多數固定音樂庫檢索場景中，我們可以透過預先計算將 RoBERTa 的特徵離線儲存，使 5 折交叉驗證時的 Bi-LSTM 峰值記憶體優化至僅 189.3 MB，記憶體消耗比 SongFormer 降低了 20.5 倍；

本框架的特徵提取與分類器是解耦的，在極度受限的即時推論環境中，RoBERTa encoder 可以被無縫替換為更輕量化的知識蒸餾版本（如 DistilRoBERTa 或 TinyBERT），這能進一步減少 40% 以上的參數與推論延遲，同時保持對結構的敏感度，在 Multimedia IoT 場景中具備極高的硬體可行性。



Q&A



Q：消融實驗顯示，移除 Section embeddings 會使 Weighted F1 下降 13.57%，說明什麼？

A：這說明「更高層次的語義上下文」對於區分音樂結構至關重要；

僅靠單行歌詞或局部窗口，模型無法掌握整段歌詞的宏觀敘事或主題一致性；

如果沒有段落級特徵 Esec，模型將無法分辨「單句語義相似、但實際上不同功能區塊」的歌詞行，導致全局結構相干性崩塌。



Q&A



Q：為什麼 RoBERTa 不 fine-tune ？

A：因為資料量有限，若 fine-tune 容易 overfitting，因此採用Frozen Encoder + Bi-LSTM。



Q&A



Q：為什麼 threshold 是0.85與0.8？

A：使用 Hyper-parameter search 決定，另外 sensitivity analysis 發現： $\pm 10\%$ 內都相當穩定

Q：為什麼不用 learnable threshold？

A：可以，但是會增加模型複雜度；固定 threshold 更符合 lightweight。



Q&A



Q：為什麼需要 Position Feature？

A：歌曲具有固定位置特性，例如：Intro 很少出現在最後；Position 提供 temporal prior。

Q：為什麼要設計 Repetition Feature？

A：因為 Chorus 最大特色就是重複，Transformer 必須自己學；我直接把 repetition 顯式提供給模型，提高辨識能力。



Q&A



Q: 為什麼要兩層 Linear，不直接 $512 \rightarrow 7$ ？

A: 若直接由 512 維映射到 7 個類別，模型的表達能力較有限；加入一層 256 維的隱藏層，並搭配 ReLU，可學習更有效的非線性特徵表示，同時降低維度，有助於提升分類效果。



Q&A



Q：為什麼這篇論文值得？

A：證明 Music Structure Analysis 不一定需要高成本 Audio Transformer

Lyrics 本身就是有效的 structural signal，只要加入：semantic、repetition、position等特徵，就可用小模型達到具有競爭力的結果，同時大幅降低記憶體需求，非常適合 Edge AI 與IoMT 應用



Q&A



Q：Structure Prior 裡面的位置特徵不是提供位置特徵了嗎，為什麼效果比SongFormer差？

A：Position 對 Intro 有幫助，但是只能提供「可能在前面」，不能告訴模型「這就是 Intro」

歌曲最前面也可能是Verse / Chorus（有些流行歌直接進 Chorus）

SongFormer看到的是 fade in / 能量逐漸增加



Q&A



Q：評估指標比較

Weighted F1：因為 dataset class imbalance 很嚴重，Chorus 約48%、Outro只有1%，Accuracy 容易失真，因此 Weighted F1 更合理。

Accuracy：提供 line-level correctness、搭配：Weighted F1、L-measure一起評估。

L-measure：評估整首歌曲結構是否一致；不是看每一行，而是看兩個時間點是否被分到同一段，因此更符合 MSA。

Q：為什麼不用 Boundary F-score？

A：因為模型預測的是 line labels，L-measure 更能反映整體 segmentation quality。



Q&A



Q：Section embedding 是不是使用了未來資訊（Information Leakage）？

A：從任務本質來看：音樂結構分析（MSA）在 MIR 領域的標準設定中，通常是一個「全曲分析」的後處理任務，而不是即時串流任務；


不論是 SOTA 的音訊模型 SongFormer，還是傳統基於音訊自相似矩陣的方法，都是在拿到整首歌曲的訊號後進行全域切分，因此，在非即時部署的場景下，讓模型知曉全曲的上下文語意是符合任務設計邏輯的。

從特徵設計的嚴謹度來看：論文中的 Section Embedding 雖然透過雙向架構融合了前後文的歌詞語意，但它完全沒有接觸到任何未來的結構標籤（Label Leakage）

它提取的是歌詞在文本結構上的「重複規律」與「相對位置」



Confusion Matrix (Proposed Model)



- Chorus 辨識效果最佳
 - 正確率最高 (89.96%)，表示模型能有效利用歌詞重複特徵辨識 Chorus。
- Verse 與 Pre-Chorus 表現穩定
 - 正確率分別為 74.51% 和 65.77%，顯示模型能學習不同段落的語意與上下文特徵。
- Intro、Bridge、Outro 容易混淆
 - Intro 常被預測為 Verse (33.01%)，Outro 常被預測為 Chorus (59.62%)，主要原因是樣本較少，且這些段落缺乏明顯且固定的歌詞特徵。



Thanks for listening!

